

bayes

Kaio Brasil

July 2024

1 Introdução

O objetivo deste arquivo é apresentar meu entendimento sobre redes bayesianas, principalmente em modelos preditores de regressão. O estudo se baseia no livro Doing Bayesian Data Analysis: A Tutorial with R and BUGS, a seguir será descrito os tópicos que achei mais importante no desenvolvimento do livro.

2 Regra de Bayes

Descreveremos a regra de bayes abaixo:

$$p(\theta|D) = \frac{p(D|\theta).p(\theta)}{p(D)} \quad (1)$$

Onde $p(D)$ é:

$$p(D) = \int d\theta.p(D|\theta)p(\theta) \quad (2)$$

A priori, $p(\theta)$, é a força da crença em θ sem os dados D . A posteriori, $p(\theta|D)$, é a força da crença em θ quando os dados foram tidos em conta.

A verossimilhança $p(D|\theta)$, é a probabilidade de os dados poderem ser gerados pelo modelo com valores de parâmetro θ . A evidência, $p(D)$, é a probabilidade dos dados de acordo com o modelo, determinada pela soma de todos os valores de parâmetros possíveis, ponderados pela força de crença nos valores dos parâmetros.

Abaixo encontramos a regra de bayes para duas variáveis:

$$p(\theta|D, M) = \frac{p(D|\theta, M) \cdot p(\theta|M)}{p(D|M)} \quad (3)$$

$p(\theta|D, M)$ é a função posteriori, $p(D|\theta, M)$ é a função de verossimilhança, $p(\theta|M)$ é a priori e $p(D|M)$ é a evidência dos dados.

A evidência dos dados pode ser expressa de outra forma que é bem mais comum ao longo do livro, onde $p(D|M)$ é igual a:

$$p(D|M) = \int d\theta p(D|\theta, M) \cdot p(\theta|M)$$

A evidência dos dados muitas vezes pode ser difícil de calcular, pois quando há muitos dados para aplicar a regra de Bayes a integral na evidência tende a se complicar. Por isso, existe um método que faz o cálculo dessas múltiplas integrais o Markov Chain Monte Carlo .MCMC.

Há também outra questão sobre a fórmula de Bayes e suas distribuições..

Na regra de Bayes se a priori em θ segue uma distribuição normal então a posteriori em θ também segue uma distribuição normal, isto pode ser encontrado no capítulo 15 do livro sobre análise.

3 Regressão Linear

Veremos a seguir a aplicação da fórmula de Bayes na regressão linear.

No modelo de regressão linear usando o método de estimação OLS, há uma suposição de erro distribuído normal que é $\epsilon \sim N(0, \sigma^2)$.

Como o erro é normalmente distribuído, as variáveis $(Y|X, \beta, \sigma^2)$ também são normalmente distribuídas. Assim, as variáveis $(Y|X, \beta, \sigma^2) \sim N(0, \sigma^2)$ e a função densidade de probabilidade (pdf) dessas variáveis são as seguintes.

$$p(Y|X, \beta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta) \right] \quad (4)$$

Com base na função de densidade de probabilidade (pdf) acima, pode ser definida a função de verossimilhança dessas variáveis da seguinte forma:

$$p(Y|X, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta) \right] \quad (5)$$

$$p(Y|X, \beta, \sigma^2) = (\sigma^2)^{-2/n} \exp \left[-\frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta) \right] \quad (6)$$

$$p(Y|X, \beta, \sigma^2) \propto (\sigma^2)^{-\frac{n}{2}} \exp \left[-\frac{vs^2}{2\sigma^2} \right] \times \exp \left[-\frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta) \right] \quad (7)$$

Existem várias distribuições anteriores que podem ser usadas na abordagem bayesiana do modelo de regressão linear, uma das quais é a distribuição do conjugado anterior. A estimação dos parâmetros do modelo de regressão com abordagem bayesiana pode ser feita iterando na marginal posterior. A distribuição posterior é calculada multiplicando a distribuição anterior e a função de verossimilhança.

$$Posterior \propto Likelihood \times Prior \quad (8)$$

$$p(\beta, \sigma^2|Y, X) \propto p(Y|X, \beta, \sigma^2)p(\sigma^2)p(\beta|\sigma^2) \quad (9)$$

$$p(\beta, \sigma^2|Y, X) \propto \quad (10)$$

$$\propto (\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta) \right] \times (\sigma^2)^{-\frac{n}{2}+1} \exp \left[-\frac{vs^2}{2\sigma^2} \right] \times (\sigma^2)^{-k/2} \exp \left[-\frac{1}{2\sigma^2} (\beta - \mu)^T (\beta - \mu) \right]$$

O processo de obtenção da estimação dos parâmetros do modelo de regressão com abordagem bayesiana pode ser feito usando o algoritmo MCMC (Markov Chain Monte Carlo). Um dos algoritmos comumente usados no MCMC é o Gibbs Sampling. Em seguida, é o processo de iteração para estimar os parâmetros até que as condições de burn-in sejam atendidas